INSTITUT TEKNOLOGI DEL
FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO
PROGRAM STUDI SARJANA SISTEM INFORMASI
Sitoluama, Laguboti, Kabupaten Toba, Sumatera Utara 22381

IDENTITAS TUGAS TERSTRUKTUR

Tanggal Sesi	:	14 Oktober 2026
Semester	:	Gasal 2026/2027
Tahun Ajaran	:	2026/2027
Mata Kuliah	:	10S3001 – Kecerdasan Buatan (+P) / 10S3001 – Artificial Intelligence (+P)
Kode Tugas	:	**Tugas 3 (Milestone 3 – W07) (Milestone Proyek Terpadu)**
Judul Tugas	:	**Pembangunan Basis Pengetahuan Korpus & Vector Semantic Search**
Bobot Nilai	:	9.0% dari Nilai Komponen Proyek (Kontribusi Nilai Akhir Semester: 2.7%)
Sifat Pengerjaan	:	Kelompok (3–4 Mahasiswa Sarjana Sistem Informasi)
Bentuk Serahan	:	Dokumen Laporan PDF (Grup{ID}-Tugas{XX}.pdf) & Tautan Repositori GitHub
Lokasi Pengumpulan	:	`https://ecourse.del.ac.id/`
Dosen Pengampu	:	Samuel Indra Gunawan Situmeang

1 Petunjuk Umum Pengerjaan

- Siapkan korpus dokumen domain *enterprise* (minimal 10–15 dokumen SOP, manual kebijakan, atau regulasi bisnis dalam format teks/PDF).
- Bangun *pipeline* pemrosesan dokumen: *word-aware chunking* terstruktur dengan *overlap*, ekstraksi *dense vector embeddings*, dan *persistent indexing* pada ChromaDB.
- Lakukan tolok ukur (*benchmark*) temu balik semantik menggunakan minimal 5 kueri uji bisnis (kueri sinonim vs kueri out-of-domain).
- Linimasa & Bobot Penilaian: Penugasan ini berbobot 9.0% dari total Komponen Proyek (2.7% dari Nilai Akhir Semester). *Milestone* ini menjadi fondasi memori semantik korpus yang krusial bagi sistem *Retrieval-Augmented Generation* (RAG).
- Kumpulkan laporan teknis PDF `Grup{KodeKelompok}-Tugas03.pdf` dan update repositori GitHub.

2 Latar Belakang & Domain Masalah Bisnis

Informasi enterprise tersebar dalam ribuan lembar dokumen SOP dan kebijakan yang sulit diakses secara cepat oleh karyawan. Sistem pencarian teks konvensional gagal menangani variasi bahasa dan kueri non-literal.

Pada Milestone 3 ini, tim Anda membangun memori semantik perusahaan (*Enterprise Knowledge Base*) menggunakan basis data vektor ChromaDB yang siap dihubungkan ke model bahasa besar pada tahap berikutnya.

3 Rincian Tugas & Luaran (Deliverables)

1. Korpus Dokumen Enterprise: Koleksi dokumen teks/PDF domain bisnis yang telah dibersihkan dan siap diindeks.
2. *Pipeline Ingestion* & *Chunking*: Skrip Python yang membagi dokumen secara rekursif dengan strategi overlap yang optimal.
3. Indeks Basis Data Vektor: *Database* persisten ChromaDB yang menyimpan vektor semantik hasil *encoding* model Sentence-Transformers.
4. Laporan Benchmark Temu Balik: Analisis skor *Cosine Similarity* pada kueri relevan, kueri ambigu, dan evaluasi presisi penolakan kueri out-of-domain.

4 Rubrik Penilaian Analitik (Skala 100, 80, 60, 40, 20, 0)

No	Komponen Penilaian	Bobot
1	**Kualitas Data Korpus & Prapemrosesan**	25%
2	**Pipeline Embedding & Vector Store ChromaDB**	45%
3	**Akurasi & Analisis Temu Balik Semantik**	30%

1. Kualitas Data Korpus & Prapemrosesan — Bobot 25%

Skor	Deskriptor Capaian
100 (Sangat Baik)	Korpus dokumen sangat representatif bagi domain enterprise, pembersihan teks bersih, dan parameter chunking (size & overlap) dijustifikasi ilmiah.
80 (Baik)	Korpus memadai, teks bersih, dan strategi pemotongan dokumen terstruktur.
60 (Cukup)	Korpus dokumen cukup namun ukuran potongan dokumen kurang optimal.
40 (Kurang)	Dokumen berantakan dan pemotongan teks memutus makna kalimat.
20 (Sangat Kurang)	Korpus tidak relevan atau teks rusak.
0 (Nol)	Tidak mengumpulkan atau plagiat mutlak.

2. Pipeline Embedding & Vector Store ChromaDB — Bobot 45%

Skor	Deskriptor Capaian
100 (Sangat Baik)	Pemilihan model embedding tepat, penyimpanan ChromaDB persisten dan modular, serta metadata tersimpan lengkap untuk hybrid search.
80 (Baik)	Integrasi ChromaDB berjalan lancar, pengindeksan persisten berhasil, dan metadata tersimpan.
60 (Cukup)	ChromaDB bekerja namun penyimpanan masih non-persisten (in-memory saja).
40 (Kurang)	Terjadi galat saat pembuatan embedding atau penyimpanan database.
20 (Sangat Kurang)	Kode pipeline embedding gagal berfungsi.
0 (Nol)	Tidak mengumpulkan atau plagiat mutlak.

3. Akurasi & Analisis Temu Balik Semantik — Bobot 30%

Skor	Deskriptor Capaian
100 (Sangat Baik)	Kueri semantik berhasil menarik dokumen target dengan Cosine Similarity tinggi, penanganan kueri out-of-domain teruji presisi, analisis mendalam.
80 (Baik)	Temu balik semantik berjalan dengan baik dan relevansi dokumen terbukti.
60 (Cukup)	Pencarian berhasil namun tidak ada evaluasi terhadap kueri di luar domain.
40 (Kurang)	Hasil temu balik seringkali tidak relevan dengan kueri uji.
20 (Sangat Kurang)	Tidak ada pengujian temu balik semantik.
0 (Nol)	Tidak mengumpulkan atau plagiat mutlak.

Tugas Terstruktur 10S3001 Kecerdasan Buatan (+P) – Institut Teknologi Del – 2026/2027